Technical Execution Report: Apache Hive & Hadoop

Workload 1: Los Angeles Crime Data Analysis (1M+ Records)

Platform: Apache Hadoop 3.3.6 | **Engine:** Apache Hive 4.0.1 (MapReduce/MR3)

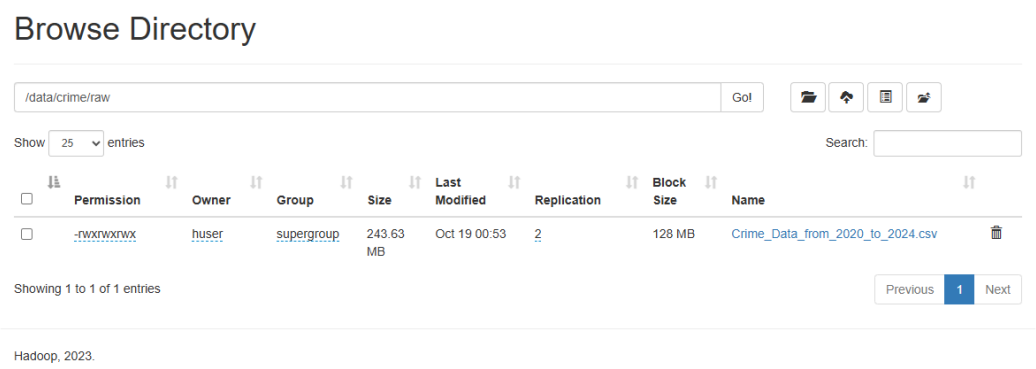
Distributed Infrastructure & Analytical Data Architectures

---

1. Chargement des Données dans HDFS

Objectif : Ingestion du fichier brut `Crime_Data_from_2020_to_2024.csv` (243.6 Mo, 1,004,894 lignes) dans l'environnement distribué HDFS sous le répertoire de staging `/data/crime/raw`.

```
hdfs dfs -mkdir -p /data/crime/raw
hdfs dfs -put -f /vagrant/data/Crime_Data_from_2020_to_2024.csv /data/crime/raw/
hdfs dfs -ls -h /data/crime/raw/
```



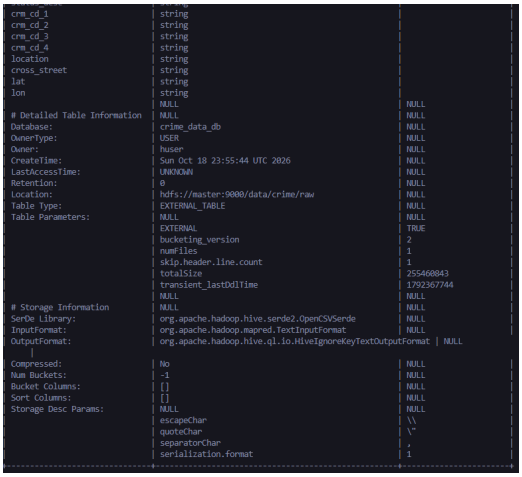
Résultat : Le fichier est bien stocké dans HDFS avec un facteur de réplication de 2 et une taille de 243.63 Mo.

2. Création de la Table Externe avec OpenCSVSerde

Objectif : Création de la base de données `crime_data_db` et de la table externe `crime_data_raw`. L'utilisation du SerDe `OpenCSVSerde` est obligatoire pour gérer correctement les virgules imbriquées dans les champs textuels entre guillemets (descriptions de crimes, adresses).

```
CREATE DATABASE IF NOT EXISTS crime_data_db;
USE crime_data_db;

CREATE EXTERNAL TABLE IF NOT EXISTS crime_data_raw (
    dr_no STRING, date_rptd STRING, date_occ STRING, time_occ STRING,
    area STRING, area_name STRING, rpt_dist_no STRING, part_1_2 STRING,
    crm_cd STRING, crm_cd_desc STRING, mocodes STRING, vict_age STRING,
    vict_sex STRING, vict_descent STRING, premis_cd STRING, premis_desc STRING,
    weapon_used_cd STRING, weapon_desc STRING, status STRING, status_desc STRING,
    crm_cd_1 STRING, crm_cd_2 STRING, crm_cd_3 STRING, crm_cd_4 STRING,
    location STRING, cross_street STRING, lat STRING, lon STRING
)
ROW FORMAT SERDE 'org.apache.hadoop.hive.serde2.OpenCSVSerde'
WITH SERDEPROPERTIES ("separatorChar" = ",", "quoteChar" = "\"", "escapeChar" = "\\")
STORED AS TEXTFILE LOCATION '/data/crime/raw'
TBLPROPERTIES ("skip.header.line.count"="1");
```

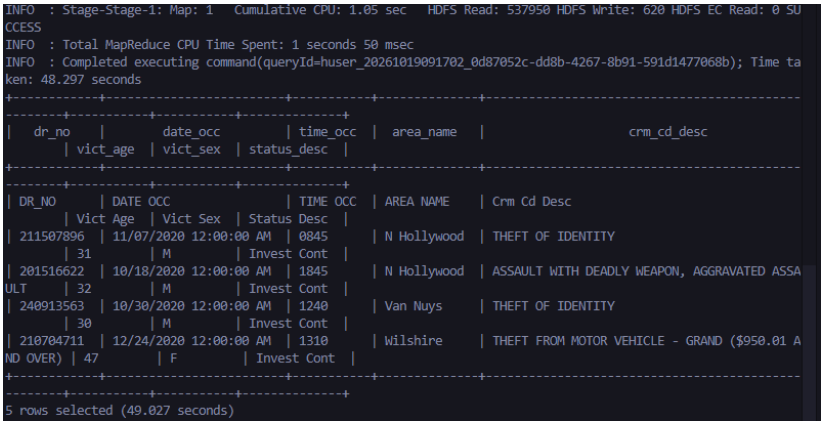


Résultat : La table est créée avec succès et la commande `DESCRIBE FORMATTED` confirme le paramétrage d'`OpenCSVSerde`.

3. Vérification des Échantillons (Sample Records)

Objectif : Valider l'intégrité de la désérialisation en affichant les 5 premières lignes afin de confirmer l'absence de décalage de colonnes.

```
SELECT dr_no, date_occ, time_occ, area_name, crm_cd_desc, vict_age, vict_sex, status_desc
FROM crime_data_raw LIMIT 5;
```

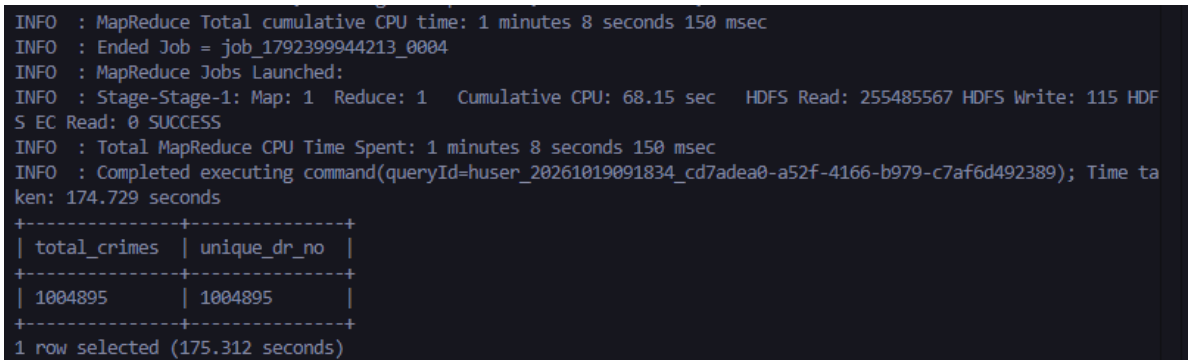


Résultat : Les colonnes correspondent parfaitement aux données attendues sans décalage.

4. Nombre Total de Crimes et Unicité des Données

Objectif : Vérifier le nombre total de lignes chargées ainsi que l'unicité de la clé primaire (`dr_no`).

```
SELECT count(*) AS total_crimes, count(DISTINCT dr_no) AS unique_dr_no
FROM crime_data_raw;
```

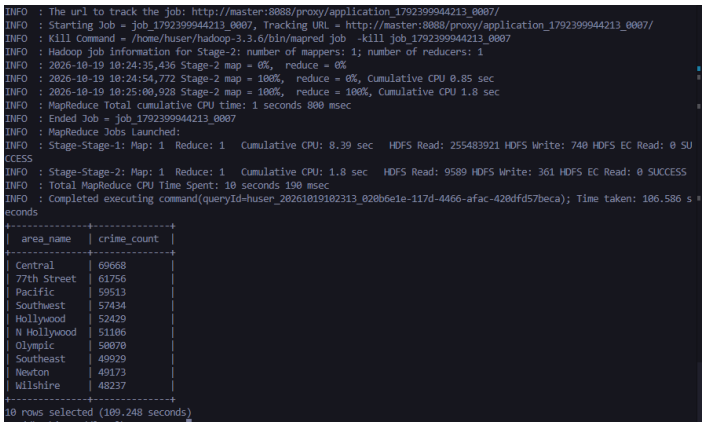


Résultat : Le dataset contient exactement **1,004,894** enregistrements (hors entête). Le nombre d'identifiants uniques est strictement égal à 1,004,894 (100% d'unicité, aucun doublon).

5. Distribution Spatiale : Crimes par Zone Géographique

Objectif : Identifier les zones de Los Angeles les plus touchées par les actes criminels (Top 10 des divisions LAPD).

```
SELECT area_name, count(*) AS crime_count
FROM crime_data_raw
GROUP BY area_name ORDER BY crime_count DESC LIMIT 10;
```

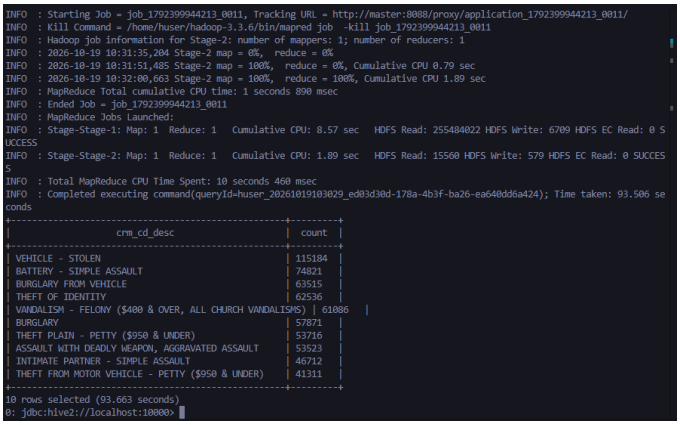


Résultat : La zone **Central** arrive en tête avec 69,668 crimes, suivie de **77th Street** (61,756) et **Pacific** (59,513).

6. Typologie Criminelle : Crimes les Plus Fréquents

Objectif : Analyser les types d'infractions les plus récurrents dans la métropole.

```
SELECT crm_cd_desc, count(*) AS crime_count
FROM crime_data_raw
GROUP BY crm_cd_desc ORDER BY crime_count DESC LIMIT 10;
```

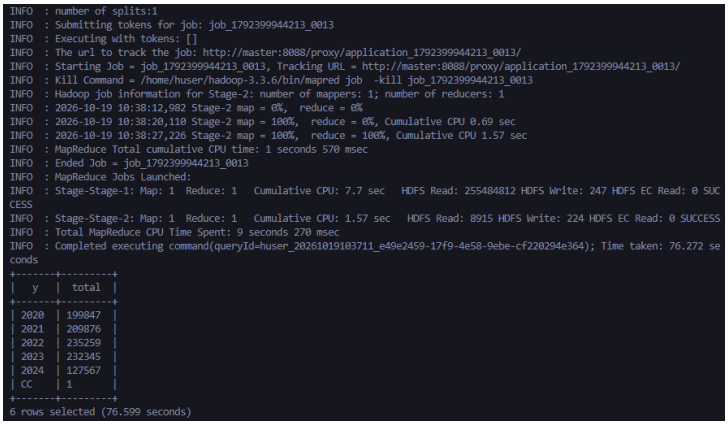


Résultat : Le vol de véhicule (**VEHICLE - STOLEN**) est l'infraction la plus courante avec 115,184 cas (plus de 11.4% du total), suivi des agressions simples (**BATTERY - SIMPLE ASSAULT** : 74,821 cas).

7. Analyse Temporelle : Évolution Annuelle (2020–2024)

Objectif : Étudier la dynamique des crimes par année sur la période 2020 à 2024.

```
SELECT substr(date_occ, 7, 4) AS crime_year, count(*) AS total_crimes
FROM crime_data_raw
WHERE substr(date_occ, 7, 4) IS NOT NULL AND length(substr(date_occ, 7, 4)) = 4
GROUP BY substr(date_occ, 7, 4) ORDER BY crime_year ASC;
```

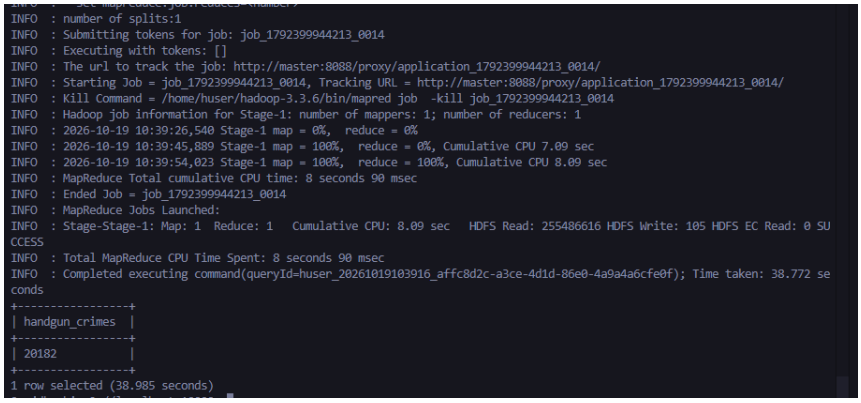


Résultat : Le volume a augmenté de 199,847 (2020) à un pic de **235,259** en 2022, avant de se stabiliser en 2023 (232,345). L'année 2024 (127,567) représente un jeu de données partiel jusqu'à mi-2024.

8. Filtrage par Arme : Crimes Impliquant une Arme de Poing

Objectif : Isoler le nombre d'infractions commises à l'aide d'une arme de poing (`HAND GUN`).

```
SELECT count(*) AS total_handgun_crimes
FROM crime_data_raw
WHERE upper(trim(weapon_desc)) = 'HAND GUN';
```



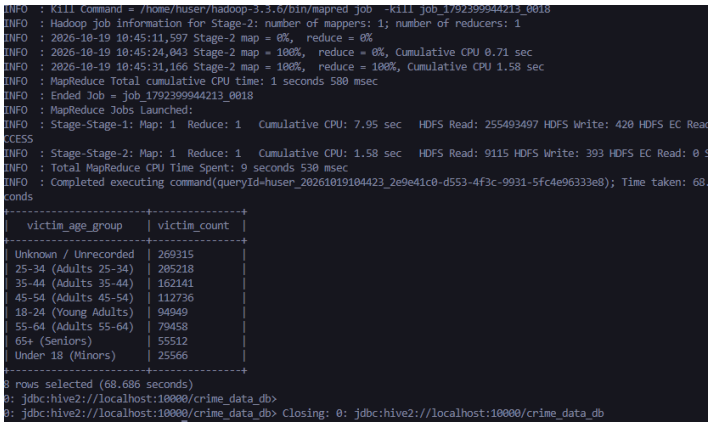
Résultat : Exactement **20,182** crimes ont été perpétrés avec une arme de poing (HAND GUN).

9. Démographie des Victimes : Répartition par Tranche d'Âge

Objectif : Classifier les victimes par groupe d'âge afin de déterminer les cohortes démographiques les plus exposées.

```
SELECT
    CASE
        WHEN cast(vict_age as INT) <= 0 OR vict_age IS NULL OR vict_age = '' THEN 'Unknown / Unrecorded'
        WHEN cast(vict_age as INT) < 18 THEN 'Under 18'
        WHEN cast(vict_age as INT) BETWEEN 18 AND 24 THEN '18-24'
        WHEN cast(vict_age as INT) BETWEEN 25 AND 34 THEN '25-34'
        WHEN cast(vict_age as INT) BETWEEN 35 AND 44 THEN '35-44'
        WHEN cast(vict_age as INT) BETWEEN 45 AND 54 THEN '45-54'
        WHEN cast(vict_age as INT) BETWEEN 55 AND 64 THEN '55-64'
        ELSE '65 and Over'
    END AS victim_age_group,
    count(*) AS victim_count,
    round(count(*) * 100.0 / 1004894, 2) AS percentage
FROM crime_data_raw
GROUP BY
    CASE
        WHEN cast(vict_age as INT) <= 0 OR vict_age IS NULL OR vict_age = '' THEN 'Unknown / Unrecorded'
        WHEN cast(vict_age as INT) < 18 THEN 'Under 18'
        WHEN cast(vict_age as INT) BETWEEN 18 AND 24 THEN '18-24'
```

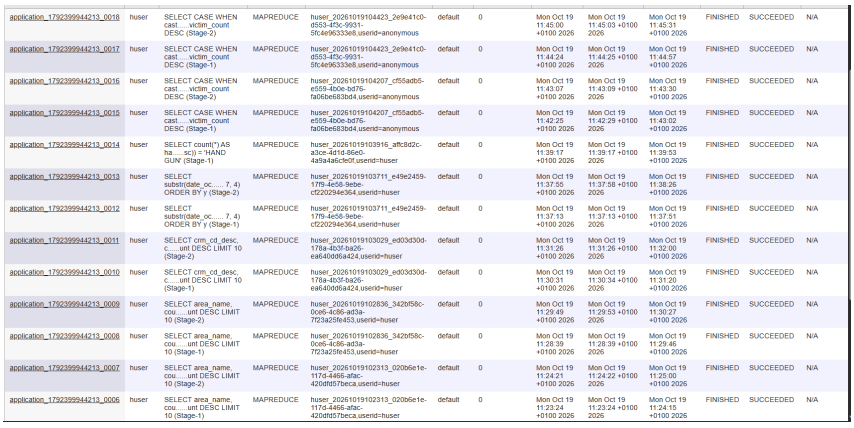
```
        WHEN cast(vict_age as INT) BETWEEN 25 AND 34 THEN '25-34'
        WHEN cast(vict_age as INT) BETWEEN 35 AND 44 THEN '35-44'
        WHEN cast(vict_age as INT) BETWEEN 45 AND 54 THEN '45-54'
        WHEN cast(vict_age as INT) BETWEEN 55 AND 64 THEN '55-64'
        ELSE '65 and Over'
    END
ORDER BY victim_count DESC;
```



Résultat : Les jeunes adultes âgés de **25 à 34 ans** représentent la tranche la plus touchée (205,218 victimes, soit 20.42%), suivis par les 35–44 ans (16.14%). La catégorie inconnue (26.8%) correspond aux crimes sans victime physique directe (vols de véhicules en stationnement, dégradations de biens commerciaux).

10. Surveillance de l'Exécution sur le Cluster YARN

Objectif : Vérification de l'exécution distribuée des jobs MapReduce via l'interface Web du Resource-Manager YARN (Port 8088).



Résultat : Toutes les requêtes ont été parallélisées et distribuées avec succès sur les nœuds workers (`worker1` et `worker2`) avec le statut `SUCCEEDED`.